САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

Факультет прикладной математики–процессов управления

Программа бакалавриата

«Большие данные и распределенная цифровая платформа»

ОТЧЕТ

По проектной работе

По дисциплине «Алгоритмы и структуры данных»

На тему «Распознавание рукописаного текста и анализ эмоциональной окраски»

Студенты гр. 24Б15-пу
Телицин А.Д.

Шаймиев К.А.

Преподаватель
Дик А.Г.

Санкт-Петербург
2026 г.

Содержание

1 Цель работы **2**

2 Теоретическая часть **2**
2.1 Распознавание текста и предобработка 2
2.2 Нейросетевая архитектура OCR 3
2.3 Датасеты и оценка качества 4
2.4 Постобработка и анализ эмоций 4

3 Используемые методы и алгоритмы, их пошаговое описание **4**
3.1 Общая архитектура программы 4
3.1.1 Загрузка датасета 5
3.1.2 Предобработка изображений 5
3.1.3 Обучение CRNN-модели 6
3.1.4 Применение обученной модели к изображениям 6
3.1.5 Постобработка текста и анализ эмоций 6
3.2 Используемые алгоритмы 7
3.2.1 CRNN (сверточная-рекуррентная нейросеть) 7
3.2.2 CTC-алгоритм 7
3.2.3 Триграммное сходство 8
3.2.4 Лемматизация с использованием pymorphy3 8
3.2.5 Подсчет распределения эмоций 8

4 Блок-схемы и диаграмма компонентов **9**
4.1 Диаграмма компонентов 9
4.1.1 Загрузка датасета 9

1 Цель работы

Целью работы является разработка программного инструмента для автоматического распознавания рукописаного текста и последующего анализа тональности распознанного содержания.

Для достижения данной цели были поставлены следующие задачи:

1. Проанализировать существующие подходы к распознаванию рукописного текста и анализу тональности.
2. Подобрать и подготовить датасет для обучения и тестирования модели.
3. Определить метрики качества и критерии успешности решения.
4. Разработать и реализовать модель распознавания рукописного текста.

2 Теоретическая часть

В этом разделе приведены ключевые термины и методы, используемые в проекте распознавания рукописного текста и анализа эмоциональной окраски. Далее они будут использоваться для описания архитектуры модели, процесса обучения и оценки качества.

2.1 Распознавание текста и предобработка

Оптическое распознавание символов (OCR, Optical Character Recognition) Автоматическое преобразование изображения с текстом в цифровую строку. *В проекте:* используется для распознавания рукописных записей на русском и английском языках.

Распознавание рукописного текста (HTR, Handwritten Text Recognition) Частный случай OCR для рукописного ввода, более сложный из-за вариативности почерка. *В проекте:* основная задача модели.

Предобработка изображения (image preprocessing) Набор операций перед подачей в модель: снижение шума, выравнивание контраста, нормализация масштаба. *В проекте:* оттенки серого, обрезка по содержимому, изменение размера, нормализация, бинаризация и удаление шума.

Изображение в оттенках серого (grayscale image) Формат, где пиксель хранит только яркость. *В проекте:* цвет несущественен, важна форма штрихов.

Нормализация изображения (image normalization) Приведение значений пикселей к единому диапазону. *В проекте:* стабилизирует вход нейросети.

Обрезка по содержимому (content crop) Удаление пустых полей вокруг текста. *В проекте:* повышает долю полезной информации во входе модели.

Бинаризация (binarization) Преобразование изображения в черно-белый вид по порогу. *В проекте:* используется как дополнительный режим, может как улучшать, так и ухудшать качество при неверном пороге.

Связная компонента (connected component) Группа соседних пикселей в бинарном изображении. *В проекте:* мелкие компоненты удаляются как шум.

Сегментация (segmentation) Разбиение изображения на строки/слова/фрагменты. *В проекте:* применяется для распознавания частей строки с последующей сборкой результата.

Профиль чернил (ink profile) Распределение темных пикселей по строкам или столбцам. *В проекте:* используется для поиска границ строк и слов без отдельной модели сегментации.

2.2 Нейросетевая архитектура OCR

Сверточная нейронная сеть (CNN, Convolutional Neural Network) Извлекает визуальные признаки: линии, углы, контуры. *В проекте:* формирует признаки рукописных символов.

Сверточный слой (convolutional layer) Применяет фильтры к изображению/картам признаков. *В проекте:* выделяет локальные элементы букв.

Пулинг (pooling) Уменьшает размер карты признаков с сохранением важной информации. *В проекте:* снижает размерность и повышает устойчивость к сдвигам.

Рекуррентная нейронная сеть (RNN, Recurrent Neural Network) Обрабатывает последовательности с учетом контекста. *В проекте:* работает с последовательностью признаков вдоль строки.

Долгая краткосрочная память (LSTM, Long Short-Term Memory) Тип RNN, лучше сохраняющий долгий контекст. *В проекте:* помогает различать похожие символы по соседним.

Двунаправленная LSTM (BiLSTM, Bidirectional LSTM) Анализирует последовательность слева направо и справа налево. *В проекте:* учитывает контекст с обеих сторон.

Сверточно-рекуррентная сеть (CRNN, Convolutional Recurrent Neural Network) Комбинация CNN и RNN для распознавания текста с изображения. *В проекте:* основная архитектура OCR.

Тензор (tensor) Многомерный числовой массив. *В проекте:* стандартный формат входа/выхода в PyTorch.

CTC-функция потерь (CTC-loss, Connectionist Temporal Classification loss) Позволяет обучать модель по парам “изображение–строка” без посимвольной разметки. *В проекте:* ключевой механизм обучения CRNN.

Декодирование CTC (CTC decoding) Преобразует последовательность вероятностей в текст (с удалением повторов и пустых символов). *В проекте:* финальный этап OCR-предсказания.

Инференс (inference) Процесс использования обученной модели для предсказания на новых данных. *В проекте:* применяется для получения результатов распознавания.

2.3 Датасеты и оценка качества

IAM Handwriting Database [1] Набор рукописного английского текста с аннотациями. *В проекте:* используется для английского OCR-пайплайна.

HKR/HTR dataset [2] Набор рукописного русского текста (изображения + JSON-аннотации). *В проекте:* основной датасет для русского OCR.

Обучающая выборка (training set) Данные для обновления параметров модели.

Валидационная выборка (validation set) Данные для контроля качества без обновления весов.

Checkpoint Файл сохраненного состояния модели. *В проекте:* позволяет запускать инференс без повторного обучения.

CER (Character Error Rate) Доля ошибок на уровне символов.

WER (Word Error Rate) Доля ошибок на уровне слов.

Расстояние Левенштейна (Levenshtein distance) Минимальное число вставок, удалений и замен для преобразования одной строки в другую. *В проекте:* используется при вычислении CER и WER.

2.4 Постобработка и анализ эмоций

Постобработка текста (text postprocessing) Очистка и нормализация OCR-результата перед дальнейшим анализом.

Токенизация (tokenization) Разбиение текста на токены (обычно слова).

Лемматизация (lemmatization) Приведение слов к начальной форме.

pymorphy3 morphological analyzer Морфологический анализатор русского языка. *В проекте:* применяется для лемматизации.

Коррекция ошибок OCR (OCR error correction) Исправление слов, распознанных с ошибками.

Триграммное сходство (trigram similarity) Сравнение слов по совпадению трехсимвольных подстрок. *В проекте:* используется при подборе корректировок.

Лексиконный анализ эмоций (lexicon-based emotion analysis) Определение эмоций по словарю с заранее размеченными словами.

RusEmoLex Русскоязычный эмоциональный словарь. *В проекте:* источник эмоциональных меток для слов.

3 Используемые методы и алгоритмы, их пошаговое описание

3.1 Общая архитектура программы

Программа состоит из нескольких основных компонентов:

- **Загрузка датасета:** чтение изображений и аннотаций из выбранного датасета.

- **Предобработка изображения:** преобразование в оттенки серого, повышение контрастности, обрезка по содержимому, изменение размера, нормализация, бинаризация и удаление шума. Приведение к матричному виду для подачи в модель.
- **Обучение CRNN-модели:** сверточно-рекуррентная нейросеть для распознавания текста.
- **Применение обученной модели к изображениям:** преобразование выходов модели в текстовую строку.
- **Постобработка текста (для русского):** токенизация, коррекция OCR-ошибок и лемматизация.
- **Анализ эмоций:** поиск слов в RusEmoLex и вычисление распределения эмоций.

3.1.1 Загрузка датасета

В качестве основного источника данных для русского языка используется HKR/HTR dataset, который содержит изображения рукописного текста и соответствующие JSON-аннотации. Для английского языка используется IAM Handwriting Database [1].

Загрузка данных для русского и английского вариантов не имеет принципиальных отличий, так как оба датасета предоставляют изображения и текстовые аннотации. Основные шаги:

1. Чтение списка файлов изображений и соответствующих аннотаций.
2. Сопоставление каждого изображения с его текстовой строкой.
3. Разделение данных на обучающую, валидационную и тестовую выборки.

3.1.2 Предобработка изображений

После загрузки изображения проходят через несколько этапов предобработки:

1. **Преобразование в оттенки серого:** удаление цветовой информации для упрощения анализа.
2. **Повышение контрастности:** позволяет повысить различимость штрихов на фоне и удалить артефакты.
3. **Обрезка по содержимому:** удаление пустых полей вокруг текста для фокусировки на полезной информации.
4. **Изменение размера:** приведение к фиксированной высоте (например, 64 пикселя) с сохранением пропорций.
5. **Нормализация:** масштабирование значений пикселей в диапазон [0, 1].
6. **Бинаризация (опционально):** преобразование в черно-белый вид по порогу для удаления шума.
7. **Приведение к матричному виду:** преобразование изображения в формат, удобный для подачи в нейросеть.

3.1.3 Обучение CRNN-модели

В работе используется сверточно-рекуррентная нейросеть (CRNN) из библиотеки PyTorch. Обучение модели происходит на обучающей выборке, а качество контролируется на валидационной выборке.

CRNN-модель состоит из нескольких сверточных слоев для извлечения признаков и рекуррентных слоев для обработки последовательности признаков. Обучение происходит следующим образом:

1. Инициализация модели и оптимизатора.
2. Проход по обучающей выборке в пакетах (батчах) заданного размера.
3. Для каждого изображения: предобработка и подача в модель.
4. Получение выходов модели в виде последовательности вероятностей символов.
5. Вычисление CTC-функции потерь между предсказанием и истинной строкой.
6. Обратное распространение ошибки и обновление весов модели.
7. Периодическая оценка на валидационной выборке для контроля качества.

На выходе обучения сохраняется файл, который содержит веса модели (checkpoint), что позволяет использовать ее для инференса без повторного обучения.

3.1.4 Применение обученной модели к изображениям

После обучения модель может быть применена к новым изображениям для получения текстовой строки. Процесс инференса включает следующие шаги:

1. Загрузка сохраненного checkpoint модели.
2. Предобработка входного изображения аналогично тому, что использовалось при обучении.
3. Подача изображения в модель и получение последовательности вероятностей символов.
4. Декодирование CTC для преобразования вероятностей в текстовую строку.
5. Если применялась сегментация, объединение результатов фрагментов в одну строку.

3.1.5 Постобработка текста и анализ эмоций

Для русского текста после получения строки из OCR применяется постобработка:

1. **Токенизация:** разбиение строки на отдельные слова.
2. **Коррекция OCR-ошибок:** для каждого слова, не найденного в словаре, поиск наиболее похожего по триграммному сходству и замена на него.
3. **Лемматизация:** приведение слов к начальной форме с помощью pymorphy3.
4. **Анализ эмоций:** для каждого лемматизированного слова поиск в RusEmoLex и подсчет распределения эмоций по тексту.

После всех этапов программа выводит несколько вариантов распознавания (с разными режимами предобработки), исправленный текст (для русского) и информацию о доминирующей эмоции и распределении эмоций в тексте.

3.2 Используемые алгоритмы

Вышеперечисленные этапы реализованы с помощью следующих алгоритмов и методов:

- **CRNN (сверточная-рекуррентная нейросеть):** сочетание сверточных и рекуррентных слоев для эффективного распознавания текста с изображений.
- **CTC-алгоритм:** позволяет обучать модель без посимвольной разметки, что критично для рукописного текста.
- **Триграммное сходство:** используется для коррекции OCR-ошибок путем сравнения с лексиконом.
- **Лемматизация с pymorphy3:** позволяет привести слова к начальной форме для более точного анализа эмоций.
- **Подсчет распределения эмоций:** суммирование эмоциональных меток из RusEmoLex для определения доминирующей эмоции.

Ниже приведено более подробное описание алгоритмов, используемых на каждом этапе.

3.2.1 CRNN (сверточная-рекуррентная нейросеть)

CRNN объединяет преимущества сверточных нейросетей (CNN) для извлечения признаков из изображений и рекуррентных нейросетей (RNN) для обработки последовательностей. Сверточная нейронная сеть является усовершенствованной версией обычной полносвязной нейронной сети. Она использует сверточные слои для извлечения локальных признаков из изображения, что позволяет эффективно распознавать сложные паттерны, такие как рукописные символы.

Рекуррентная нейронная сеть, в свою очередь, обрабатывает последовательность признаков, учитывая контекст и взаимосвязи между символами. Это особенно важно для рукописного текста, где форма символов может сильно варьироваться в зависимости от соседних символов. В нашем случае архитектура включает:

- Несколько сверточных слоев для извлечения признаков. Каждый слой применяет набор фильтров к входному изображению или карте признаков, выделяя сложные геометрические шаблоны, характерные для рукописного текста.
- Пулинг-слои для снижения размерности.
- Двунаправленные LSTM-слои для обработки последовательности признаков.
- Выходной слой с активацией softmax для получения вероятностей символов.

3.2.2 CTC-алгоритм

CTC (Connectionist Temporal Classification) — это алгоритм, который позволяет обучать модели распознавания текста без необходимости в посимвольной разметке. Он работает следующим образом:

- Модель генерирует последовательность вероятностей для каждого символа (включая специальный символ "пусто") на каждом временном шаге. Вероятности получаеются на выходе сверточно-рекуррентной нейросети после обработки входного изображения.

- CTC-функция потерь вычисляет вероятность правильного распознавания строки, суммируя по всем возможным выравниваниям между входной последовательностью и целевой строкой.
- Во время инференса декодирование CTC удаляет повторяющиеся символы и пустые символы, чтобы получить итоговую строку.

Преимущество CTC заключается в том, что он позволяет обучать модель на данных, где нет точного выравнивания между входом и выходом, что идеально подходит для рукописного текста.

3.2.3 Триграммное сходство

Данный алгоритм используется для коррекции ошибок OCR. Он работает следующим образом:

- Для каждого слова, распознанного OCR, которое не найдено в словаре, генерируется множество триграмм (последовательностей из трех символов).
- Для каждого слова в словаре также генерируются триграммы.
- Вычисляется сходство между распознанным словом и каждым словом в словаре на основе количества совпадающих триграмм.
- Слово из словаря с наибольшим сходством выбирается в качестве корректировки для распознанного слова.

3.2.4 Лемматизация с использованием pymorphy3

Лемматизация — это процесс приведения слова к его начальной форме (лемме). В нашем проекте для русского языка используется библиотека pymorphy3, которая предоставляет мощные инструменты для морфологического анализа. Процесс лемматизации включает следующие шаги:

- Для каждого слова, полученного после коррекции OCR-ошибок, вызывается функция лемматизации из pymorphy3.
- Библиотека анализирует слово и возвращает его лемму, которая используется для дальнейшего анализа эмоций.

3.2.5 Подсчет распределения эмоций

Для анализа эмоциональной окраски текста используется лексикон RusEmoLex, который содержит слова и их эмоциональные метки. Процесс подсчета распределения эмоций включает следующие шаги:

- Для каждого лемматизированного слова выполняется поиск в RusEmoLex.
- Если слово найдено, его эмоциональные метки добавляются к общему счетчику для каждой эмоции.
- После обработки всех слов вычисляется распределение эмоций, и определяется доминирующая эмоция.

4 Блок-схемы и диаграмма компонентов

4.1 Диаграмма компонентов

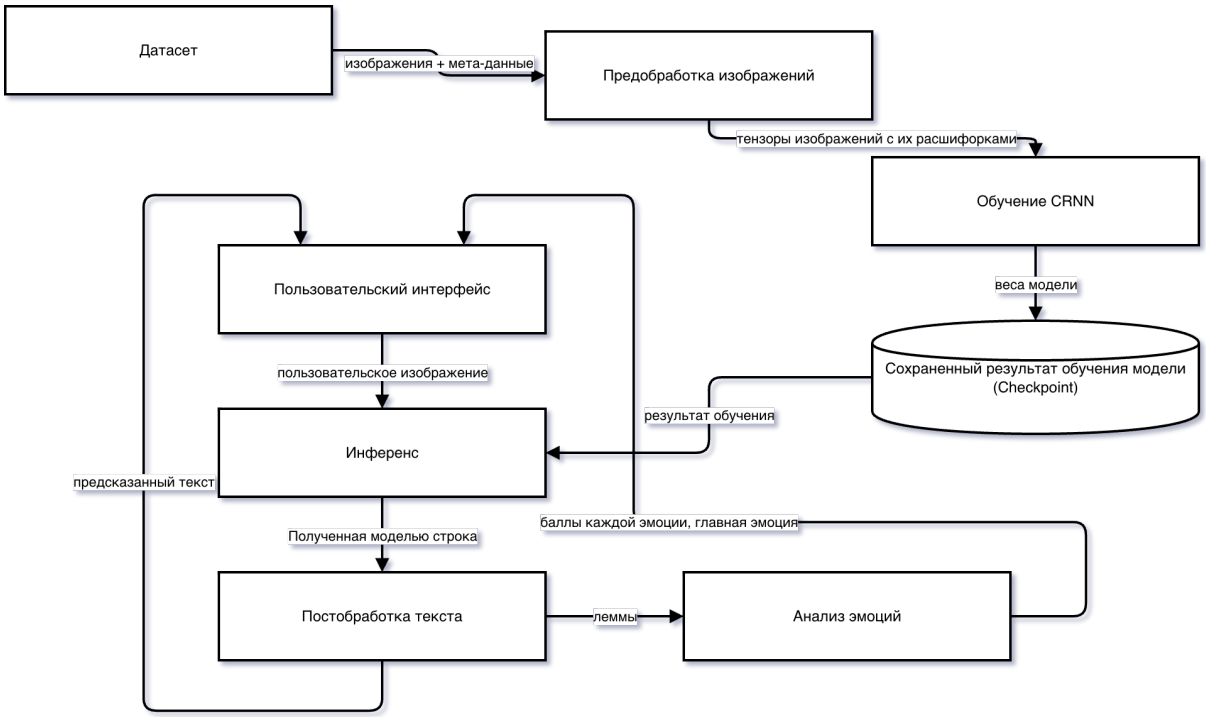

Рис. 1: Диаграмма компонентов программы

4.1.1 Загрузка датасета

Список литературы

[1] U. Marti and H. Bunke. The IAM-database: An English Sentence Database for Offline Handwriting Recognition. Int'l Journal on Document Analysis and Recognition, Volume 5, pages 39 - 46, 2002.

[2] Handwritten Kazakh and Russian (HKR) database for text recognition.